FACULTAD DE CIENCIA & TECNOLOGÍA

INGENIERÍA EN SISTEMAS

ANÁLISIS DE DATOS

ANÁLISIS DE UN SISTEMA DE PEDIDOS INTERNACIONALES

DOCENTE:

ING. CARLOS DRAUGIALIS PESSOA

ESTUDIANTE:

JUNIOR SESARIO HUANCA ACEBO

SANTA CRUZ – BOLIVIA

ÍNDICE DE CONTENIDO

1. INTRODUCCIÓN 1

2. OBJETIVOS 2

2.1. Objetivo general 2

2.2. Objetivos específicos 2

3. PREPARACIÓN Y DATOS 3

3.1. Fuentes de los datos 3

3.2. Limpieza de datos 4

3.2.1. Valores faltantes: 5

3.2.2. Duplicados: 5

3.2.3. Valores atípicos: 5

3.2.4. Errores de formato: 5

3.3. Ingeniería de características 6

3.4. División de datos 6

4. ANÁLISIS Y RESULTADOS 6

4.1. Análisis exploratorio de datos (EDA) 7

4.2. Visualizaciones claves 12

4.3. Visualizaciones generales 14

4.3.1. Histogramas 15

4.3.2. Función empírica 16

4.3.3. Serie de tiempo 16

4.3.4. Diagrama de dispersión 17

4.3.5. Gráfica de barras 18

4.3.6. Matriz de correlación 18

4.3.7. Diagrama de pares 19

4.3.8. Diagrama de caja 20

5. CONCLUSIONES Y RECOMENDACIONES 22

5.1. Conclusiones 22

5.2. Recomendaciones 23

5.3. Apéndices 23

ÍNDICE DE FIGURAS

Figura 1. Productos (500 registros) 7

Figura 2. Categorías de productos (20 registros) 7

Figura 3. Proveedores (40 registros) 7

Figura 4. Inventario (2.400 registros) 8

Figura 5. Almacenes (12 registros) 8

Figura 6. Clientes (211 registros) 8

Figura 7. Direcciones de clientes (1–3 por cliente – 418 registros) 9

Figura 8. Pedidos (1.000 registros) 9

Figura 9. Elementos del pedido (12.000 líneas) 9

Figura 10. Pagos (921 registros) 10

Figura 11. Envíos (741 registros) 10

Figura 12. Eventos de envío (2.400 registros) 10

Figura 13. Empleados (80 registros) 11

Figura 14. Diagrama de clases (relación entre clases) 11

Figura 15. Estado de pedidos 12

Figura 16. Pedidos por mes 13

Figura 17. Distribución de pagos 13

Figura 18. Ventas diarias 14

Figura 19. Frecuencia de delta_days 15

Figura 20. Retrasos moderados vs prolongados 15

Figura 21. Tiempo estimado de entrega y real de los pedidos 16

Figura 22. Cantidad de envíos con retraso 16

Figura 23. Cantidad de ordenes al mes con estados de entregas 17

Figura 24. Distancia y días de retrasos 17

Figura 25. Conteo de ordenes y estado de llegada 18

Figura 26. Órdenes completadas 18

Figura 27. Pair plots 19

Figura 28. Total de ventas y hora de llegada 20

Figura 29. Delta_days por estado y tipo de retraso 21

RESUMEN EJECUTIVO

El proyecto se enfocó en el análisis de un sistema de pedidos internacionales, con el fin de integrar información dispersa en distintas fuentes como clientes, pedidos, productos, pagos, envíos e inventario. La meta fue unificar estos datos para obtener una visión clara del ciclo completo de compra y venta.

Para el desarrollo se empleó el lenguaje de Python dentro de un entorno Jupyter Notebook, lo que permitió documentar de manera ordenada el proceso de análisis. Se utilizaron diversas librerías, entre ellas Pandas para la manipulación de datos, NumPy para operaciones numéricas, Matplotlib para la generación de visualizaciones y os para la gestión de rutas de archivos. Además, se incluyó la librería warnings con el fin de controlar la aparición de advertencias durante la ejecución. gráficas que facilitaron la interpretación de los datos en el tiempo.

Los resultados mostraron la importancia de unificar adecuadamente la información para evitar duplicaciones y pérdidas de registros. Además, se identificaron patrones en los estados de los pedidos y variaciones en las ventas a lo largo del tiempo.

Se recomienda automatizar la limpieza y organización de los datos para reducir errores y mantener la consistencia. También es necesario definir reglas para evitar duplicaciones, como seleccionar una dirección principal por cliente o consolidar varios pagos en uno solo. Además, conviene ampliar los indicadores de análisis con métricas de clientes frecuentes y productos más vendidos, y utilizar herramientas de inteligencia de negocios como Power BI o Tableau para crear paneles interactivos que faciliten el seguimiento de las ventas y del comportamiento de los clientes.

1. INTRODUCCIÓN

El comercio internacional basado en pedidos en línea ha crecido de manera exponencial en los últimos años, generando una gran cantidad de datos que provienen de distintas áreas del negocio: clientes, productos, proveedores, inventario, empleados, pedidos, pagos y envíos. La correcta integración y análisis de esta información es fundamental para que las organizaciones logren comprender el ciclo completo de sus operaciones, optimicen la gestión de recursos y mejoren la toma de decisiones estratégicas.

En este proyecto se trabajó con un dataset de pedidos internacionales compuesto por 13 tablas relacionadas entre sí. Estas tablas incluyen información diversa, desde los datos básicos de los clientes y sus direcciones, hasta detalles de los productos, proveedores, almacenes, inventario, pedidos realizados, artículos por pedido, envíos, eventos de seguimiento de esos envíos, empleados y pagos asociados. La diversidad de fuentes y la complejidad de las relaciones entre ellas plantearon el reto de consolidar toda la información en un único modelo de análisis, eliminando duplicaciones e inconsistencias para poder generar indicadores confiables.

La importancia de este análisis radica en que la información consolidada constituye una base sólida para la gestión empresarial en un contexto de comercio internacional. Gracias a ella, una organización puede comprender mejor el comportamiento de sus clientes, identificar tendencias de demanda, evaluar la eficiencia de su cadena de suministro y fortalecer su capacidad de respuesta en un mercado altamente competitivo. Además, este proyecto sirve como modelo replicable para otros entornos de negocio donde la integración de datos dispersos sea una necesidad clave para impulsar la eficiencia operativa y la estrategia comercial.

2. OBJETIVOS

2.1. Objetivo general

Unificar y analizar la información de un sistema de pedidos internacionales proveniente de múltiples fuentes de datos, con el fin de consolidar un modelo integrado que permita obtener una visión clara, coherente y confiable del ciclo completo de compra y venta, apoyando la toma de decisiones estratégicas en el comercio internacional.

2.2. Objetivos específicos

- Importar y preparar los datos desde archivos CSV, garantizando la correcta lectura de las 13 tablas y la asignación adecuada de tipos de datos.
- Depurar la información mediante la detección y corrección de duplicados, inconsistencias y valores redundantes.z
- Calcular métricas clave como el número de productos por transacción, montos de venta totales y frecuencia de pedidos.
- Identificar patrones en los estados de los pedidos (confirmados, completados, cancelados, devueltos) y en el comportamiento de compra de los clientes.
- Generar estadísticas descriptivas y visualizaciones que permitan analizar las ventas, los clientes y los procesos logísticos a lo largo del tiempo.
- Exportar los resultados a un archivo consolidado como producto final del análisis, listo para servir de base en futuros desarrollos de inteligencia de negocios.

3. PREPARACIÓN Y DATOS

El proceso de preparación de datos fue esencial para garantizar que el análisis realizado sobre el sistema de pedidos internacionales fuese confiable, consistente y útil para la toma de decisiones. A continuación, se describen con detalle los principales aspectos de esta etapa:

3.1. Fuentes de los datos

Los datos utilizados en el proyecto provienen de un dataset de pedidos internacionales conformado por 13 archivos en formato CSV y una base SQLite llamada international_orders.sqlite.

Cada archivo representa una tabla con información específica:

- Productos (Products): Representa los artículos que la tienda vende. Incluye información como el nombre, la categoría a la que pertenece y su proveedor.
- Categorías de Productos (Product Categories): Organiza los productos en grupos lógicos, facilitando la navegación y la gestión.
- Proveedores (Suppliers): Entidades que suministran los productos a la tienda. Se registra su información de contacto y país.
- Inventario (Inventory): Detalla la cantidad de cada producto disponible en un almacén específico. Esto ayuda a gestionar el stock y los puntos de reorden.
- Almacenes (Warehouses): Ubicaciones físicas donde se almacena el inventario. Cada almacén tiene información de ubicación y moneda asociada.
- Clientes (Customers): Las personas o entidades que compran los productos. Se registran sus datos de contacto, preferencias de moneda y direcciones.

- Direcciones de Clientes (Customer Addresses): Las diferentes direcciones asociadas a un cliente (por ejemplo, facturación, envío).
- Pedidos (Orders): Las transacciones de compra realizadas por los clientes. Un pedido incluye detalles sobre el cliente, la fecha, el estado y los artículos comprados.
- Elementos del Pedido (Order Items): Los productos específicos y la cantidad que componen un pedido. Aquí se manejan detalles como el precio unitario y los descuentos.
- Pagos (Payments): Las transacciones financieras asociadas a los pedidos. Se registra el método de pago, la fecha y el monto.
- Envíos (Shipments): La logística para entregar los pedidos a los clientes. Incluye información del transportista, número de seguimiento y costos.
- Eventos de Envío (Shipment Events): Los hitos o actualizaciones en el proceso de envío (por ejemplo, "en tránsito", "entregado").
- Empleados (Employees): El personal que trabaja para la tienda, con detalles sobre su rol y fecha de contratación.

Todos los archivos fueron importados en Jupyter Notebook utilizando la librería panda, y se asignaron tipos de datos específicos para evitar errores de interpretación (ej. identificadores como enteros, precios como flotantes, y fechas como datetime).

3.2. Limpieza de datos

El dataset original contenía inconsistencias propias de fuentes múltiples, por lo que se aplicaron diferentes procesos de limpieza:

3.2.1. Valores faltantes:

- Se identificaron en columnas de fechas y en algunos registros sin pagos asociados.
- En lugar de imputar valores artificiales, se mantuvieron nulos cuando representaban casos reales (ej. pedidos sin pago).

3.2.2. Duplicados:

- En las direcciones de clientes, algunos registros repetían la misma información.
- Se aplicó drop_duplicates () conservando solo una dirección principal por cliente.

3.2.3. Valores atípicos:

- Se revisaron columnas como stock_qty e inventory.reorder_point para detectar valores extremos. Estos casos fueron validados y mantenidos, ya que podían reflejar situaciones reales de inventario alto o bajo.

3.2.4. Errores de formato:

- Todas las columnas de fechas (order_date, created_at, payment_date, ship_date, event_time, etc) fueron convertidas a formato datetime para un manejo correcto en análisis temporales.
- Se renombraron columnas que generaban confusión al unirse tablas (ejemplo: status_x → order_status y status_y → payment_status).

3.3. Ingeniería de características

Aunque no se crearon variables predictivas complejas, sí se generaron nuevos indicadores derivados de los datos originales, que enriquecieron el análisis:

- Total de productos por pedido: a partir del conteo de order_items.
- Monto total de venta por pedido: calculado como (cantidad × precio unitario) - descuentos.
- Ventas diarias consolidadas: agregación de ventas por fecha de pedido, permitiendo observar la evolución del negocio en el tiempo.
- Variables de estado unificadas: diferenciando entre estado del pedido (order_status) y estado del pago (payment_status).

3.4. División de datos

En este proyecto no se aplicaron modelos predictivos, por lo que no fue necesario dividir los datos en conjuntos de entrenamiento, validación y prueba. El trabajo se centró en el análisis descriptivo y la visualización de patrones de negocio. Sin embargo, gracias a la consolidación lograda, el dataset final puede servir como base para futuros desarrollos en analítica predictiva (ej. predicción de demanda, segmentación de clientes o detección de riesgo de cancelaciones).

4. ANÁLISIS Y RESULTADOS

El análisis realizado sobre el sistema de pedidos internacionales permitió obtener una visión integral de los datos, destacando aspectos relevantes tanto de los clientes como de los pedidos, pagos y envíos. A continuación, se presentan los principales hallazgos, acompañados de visualizaciones que facilitaron la interpretación de la información.

4.1. Análisis exploratorio de datos (EDA)

Se inició con un análisis exploratorio de las 13 tablas que conforman el dataset. Las herramientas estadísticas básicas (head(), info(), describe()) permitieron verificar la calidad de los datos, los rangos de valores y la ausencia de errores críticos.

Figura 1. Productos (500 registros)

```
products.head()
```

	product_id	sku	product_name	category_id	supplier_id	unit_price_usd	weight_kg	is_active
0	1	SKU-00001	Producto 0001	5	34	193.34	0.88	0
1	2	SKU-00002	Producto 0002	17	2	53.87	3.81	1
2	3	SKU-00003	Producto 0003	15	12	49.96	0.25	1
3	4	SKU-00004	Producto 0004	20	1	34.14	2.22	1
4	5	SKU-00005	Producto 0005	5	12	74.91	1.04	1

Figura 2. Categorías de productos (20 registros)

```
product_categorias.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20 entries, 0 to 19
Data columns (total 2 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   category_id    20 non-null     int64
 1   category_name  20 non-null     object
dtypes: int64(1), object(1)
memory usage: 452.0+ bytes
```

Figura 3. Proveedores (40 registros)

```
suppliers.head()
```

	supplier_id	supplier_name	country	country_code	currency	contact_name	phone	email
0	1	Supplier 001	Italy	IT	EUR	Isabella Singh	+84-149-174-9779	supplier1543@demo.org
1	2	Supplier 002	New Zealand	NZ	NZD	Elijah Ivanov	+28-138-188-8104	supplier6852@example.com
2	3	Supplier 003	Germany	DE	EUR	Sofia Kumar	+55-160-946-3028	supplier3658@sample.co
3	4	Supplier 004	Canada	CA	CAD	Jacob Singh	+7-326-147-3181	supplier4745@company.net
4	5	Supplier 005	Argentina	AR	ARS	Zoe Davis	+74-415-673-3961	supplier1689@sample.co

Figura 4. Inventario (2.400 registros)

```
inventory.describe()
```

	inventory_id	warehouse_id	product_id	stock_qty	reorder_point
count	2400.000000	2400.000000	2400.000000	2400.000000	2400.00000
mean	1200.500000	6.500000	247.530833	125.179167	34.40875
std	692.964646	3.452772	144.535284	57.408698	14.19004
min	1.000000	1.000000	1.000000	5.000000	5.00000
25%	600.750000	3.750000	120.750000	85.000000	25.00000
50%	1200.500000	6.500000	246.000000	123.500000	35.00000
75%	1800.250000	9.250000	371.000000	165.000000	44.00000
max	2400.000000	12.000000	500.000000	349.000000	88.00000

Figura 5. Almacenes (12 registros)

```
warehouses.head()
```

	warehouse_id	warehouse_name	country	country_code	currency
0	1	WH-BR-01	Brazil	BR	BRL
1	2	WH-PY-02	Paraguay	PY	PYG
2	3	WH-JP-03	Japan	JP	JPY
3	4	WH-CA-04	Canada	CA	CAD
4	5	WH-PE-05	Peru	PE	PEN

Figura 6. Clientes (211 registros)

```
customers.sample(10)
```

	customer_id	customer_name	email	phone	country	country_code	preferred_currency	created_at
76	77	Elijah Khan	elijahkhan253@company.net	+86-793-545-9202	Italy	IT	EUR	2024-01-05 22:58:50+00:00
150	151	Charlotte Williams	charlottewilliams880@sample.co	+73-461-823-8302	Argentina	AR	ARS	2024-03-26 07:43:27+00:00
207	208	Leo Ivanov	leoivanov8598@mail.com	+45-576-613-6038	Brazil	BR	BRL	2025-01-30 07:57:30+00:00
24	25	Zoe Johnson	zoejohnson3094@company.net	+21-192-975-3039	Germany	DE	EUR	2025-01-15 20:48:33+00:00
96	97	Jacob Patel	jacobpatel6390@mail.com	+19-423-472-8322	Bolivia	BO	BOB	2023-11-12 19:35:23+00:00
49	50	Mila Johnson	milajohnson9616@company.net	+16-641-960-2570	Netherlands	NL	EUR	2023-04-20 08:01:42+00:00
43	44	Mila Kowalski	milakowalski3994@demo.org	+50-981-154-8832	Poland	PL	PLN	2022-09-29 14:32:21+00:00
4	5	Leo Ramirez	leoramirez680@company.net	+79-711-882-6353	Paraguay	PY	PYG	2024-01-02 17:18:06+00:00
206	207	Isabella Zhang	isabellazhang7174@demo.org	+90-733-589-2103	Chile	CL	CLP	2023-11-02 04:02:23+00:00
94	95	Olivia Costa	oliviacosta3754@mail.com	+65-528-629-8267	France	FR	EUR	2024-12-14 07:03:00+00:00

Figura 7. Direcciones de clientes (1–3 por cliente – 418 registros)

```
customer_addresses.head()
```

	address_id	customer_id	type	line1	city	state_province	postal_code	country	country_code
0	1	1	shipping	Calle 3006	Ciudad 384	SP-62	78417	Italy	IT
1	2	2	shipping	Calle 972	Ciudad 231	SP-36	82349	Canada	CA
2	3	2	shipping	Calle 6418	Ciudad 393	SP-20	93627	United Arab Emirates	AE
3	4	2	billing	Calle 3090	Ciudad 489	SP-15	74915	Netherlands	NL
4	5	3	billing	Calle 9511	Ciudad 260	SP-91	53438	Netherlands	NL

Figura 8. Pedidos (1.000 registros)

```
orders.sample(10)
```

	order_id	customer_id	order_date	status	sales_rep_id	shipping_address_id	currency
704	705	204	2022-09-11 11:17:19+00:00	pending	23	401	EUR
520	521	99	2024-01-18 13:22:34+00:00	cancelled	46	205	EUR
858	859	140	2024-02-09 13:49:42+00:00	confirmed	56	288	AED
765	766	199	2024-01-04 21:25:33+00:00	confirmed	15	393	USD
355	356	150	2023-07-24 05:48:24+00:00	pending	2	304	CAD
723	724	66	2024-03-29 08:36:43+00:00	fulfilled	7	140	ZAR
119	120	69	2022-10-16 12:14:01+00:00	pending	78	147	USD
158	159	42	2025-02-25 22:08:48+00:00	fulfilled	68	86	CLP
899	900	51	2024-01-11 22:49:28+00:00	confirmed	55	106	ZAR
233	234	161	2023-05-22 07:47:42+00:00	fulfilled	80	322	PYG

Figura 9. Elementos del pedido (12.000 líneas)

```
items.head()
```

	order_item_id	order_id	line_number	product_id	qty	unit_price_usd	discount
0	1	1	1	316	2	14.83	0.00
1	2	1	2	75	3	37.44	0.00
2	3	1	3	440	1	33.70	0.00
3	4	1	4	236	4	21.90	0.00
4	5	1	5	159	5	45.86	0.07

Figura 10. Pagos (921 registros)

```
payments.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 921 entries, 0 to 920
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   payment_id    921 non-null    int64
 1   order_id      921 non-null    int64
 2   payment_date  921 non-null    object
 3   amount_usd    921 non-null    float64
 4   method        921 non-null    object
 5   status        921 non-null    object
dtypes: float64(1), int64(2), object(3)
memory usage: 43.3+ KB
```

Figura 11. Envíos (741 registros)

```
shipments.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 741 entries, 0 to 740
Data columns (total 7 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   shipment_id          741 non-null    int64
 1   order_id             741 non-null    int64
 2   ship_date            741 non-null    object
 3   carrier              741 non-null    object
 4   tracking_number      741 non-null    object
 5   shipping_cost_usd    741 non-null    float64
 6   origin_warehouse_id  741 non-null    int64
dtypes: float64(1), int64(3), object(3)
memory usage: 40.7+ KB
```

Figura 12. Eventos de envío (2.400 registros)

```
shipment_events.sample(5)
```

	shipment_event_id	shipment_id	event_time	event_type	location
666	667	196	2024-08-13 06:00:08+00:00	picked_up	Japan
1083	1084	315	2023-08-29 03:44:50+00:00	label_created	Brazil
380	381	109	2024-01-18 08:33:42+00:00	in_transit	Paraguay
606	607	178	2023-09-06 20:07:27+00:00	out_for_delivery	India
235	236	71	2024-03-21 18:17:47+00:00	label_created	Peru

Figura 13. Empleados (80 registros)

```
employees.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 80 entries, 0 to 79
Data columns (total 7 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   employee_id  80 non-null     int64
 1   full_name    80 non-null     object
 2   role         80 non-null     object
 3   email        80 non-null     object
 4   country      80 non-null     object
 5   hired_at     80 non-null     object
 6   active       80 non-null     int64
dtypes: int64(2), object(5)
memory usage: 4.5+ KB
```

Figura 14. Diagrama de clases (relación entre clases)

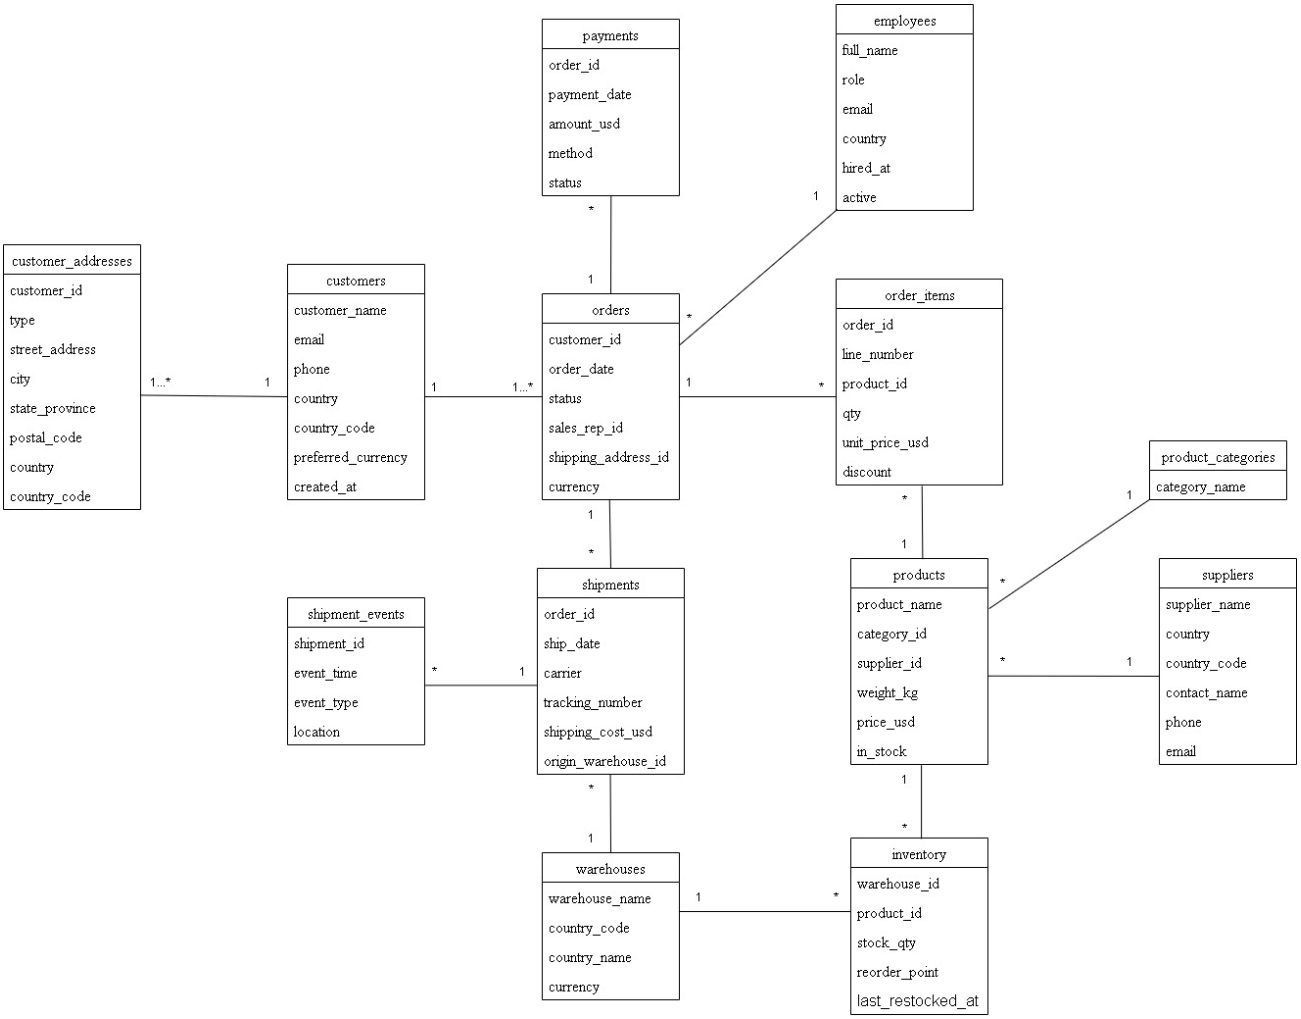

4.2. Visualizaciones claves

El análisis se centró en los aspectos que más influyen en la operación del negocio: pedidos, pagos y ventas.

Figura 15. Estado de pedidos

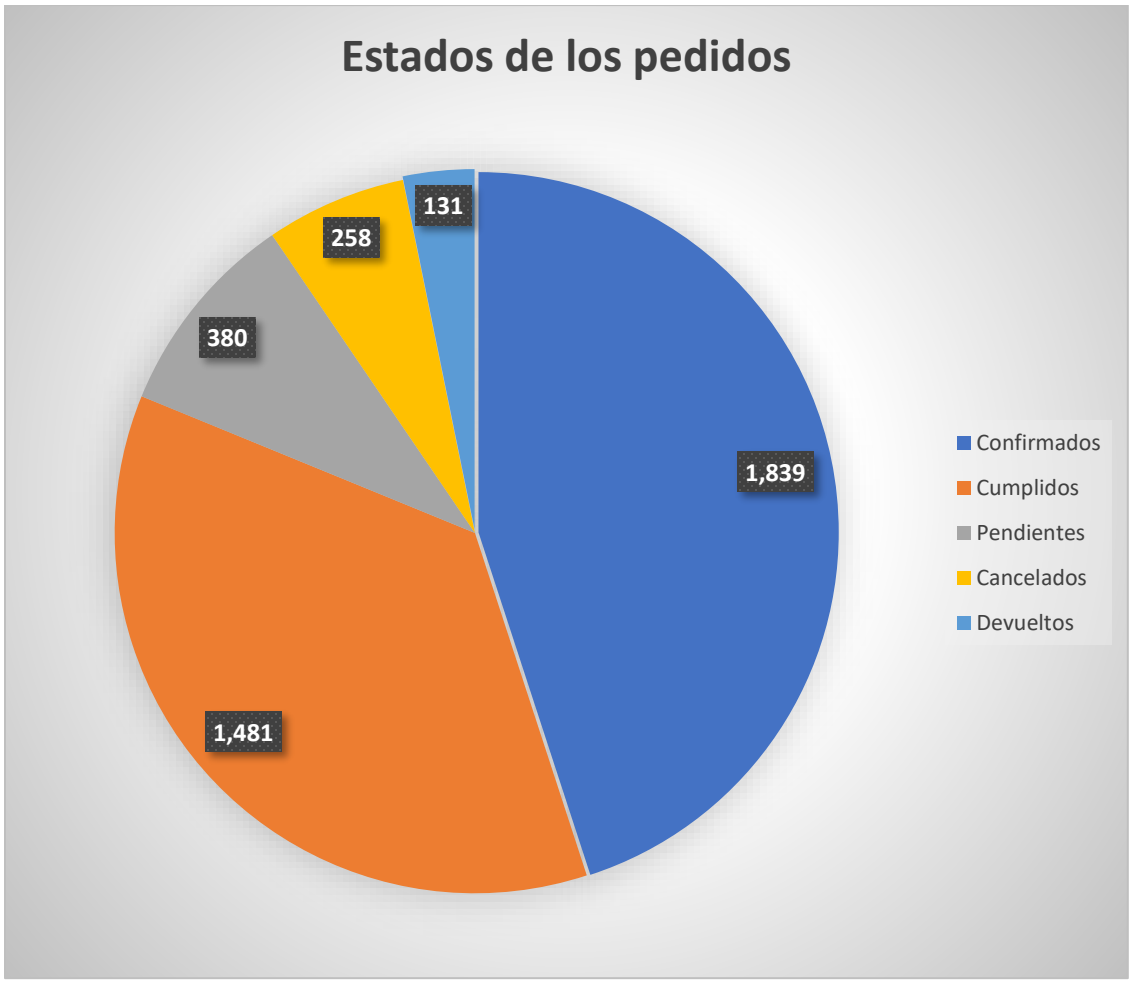

Interpretación: Esta información revela que la mayoría de los pedidos llega a completarse satisfactoriamente, aunque existe un porcentaje de cancelaciones y devoluciones que la empresa debe gestionar.

Figura 16. Pedidos por mes

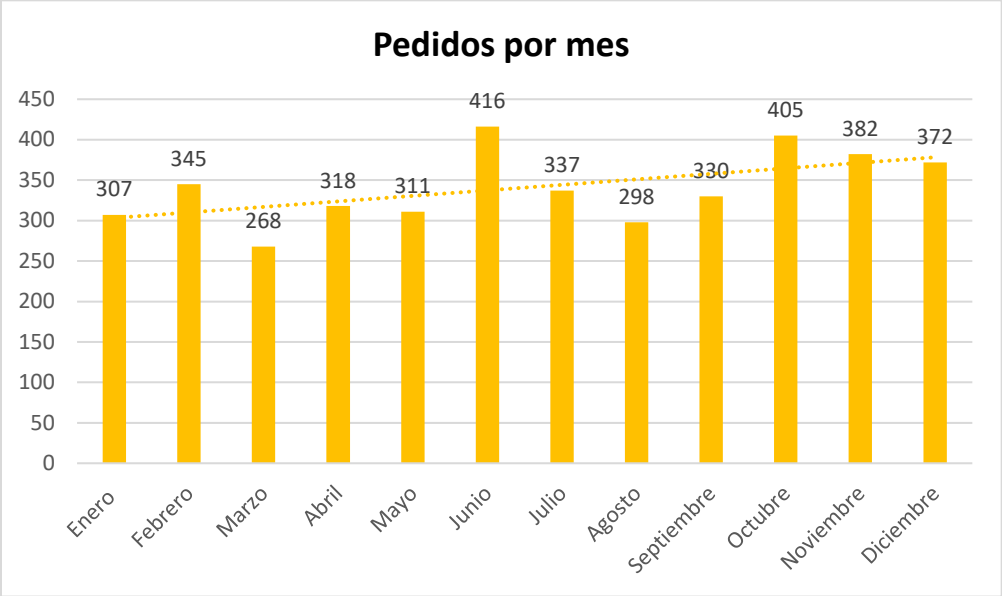

Interpretación: El análisis temporal mostró que los pedidos se distribuyen de manera relativamente uniforme a lo largo del año, con ligeros picos en los meses de junio (416 pedidos) y octubre (405 pedidos). Esto puede asociarse a temporadas de mayor demanda o campañas de ventas internacionales.

Figura 17. Distribución de pagos

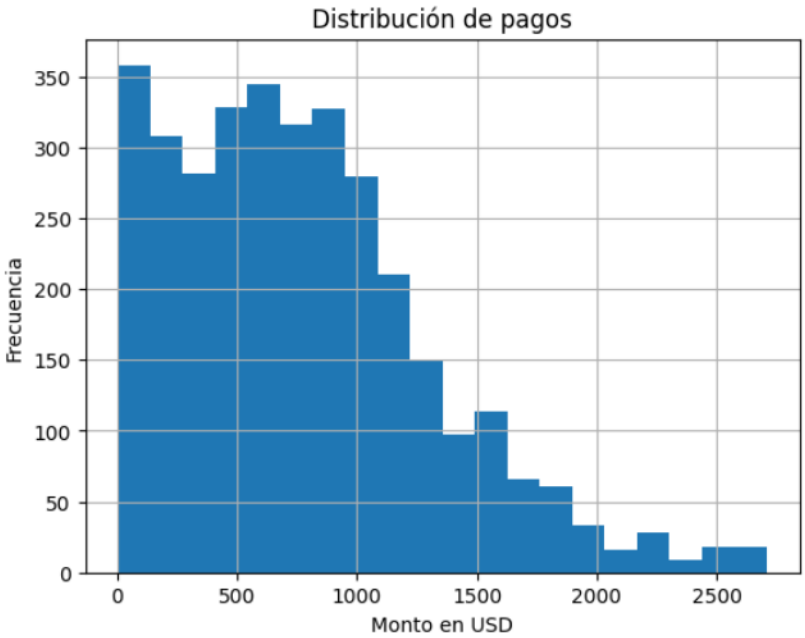

Interpretación: El histograma de pagos evidenció que la mayoría de las transacciones se concentran en montos bajos y medios, aunque existen algunos casos de pagos de mayor valor que representan operaciones relevantes. Esto permite identificar clientes de alto valor.

Figura 18. Ventas diarias

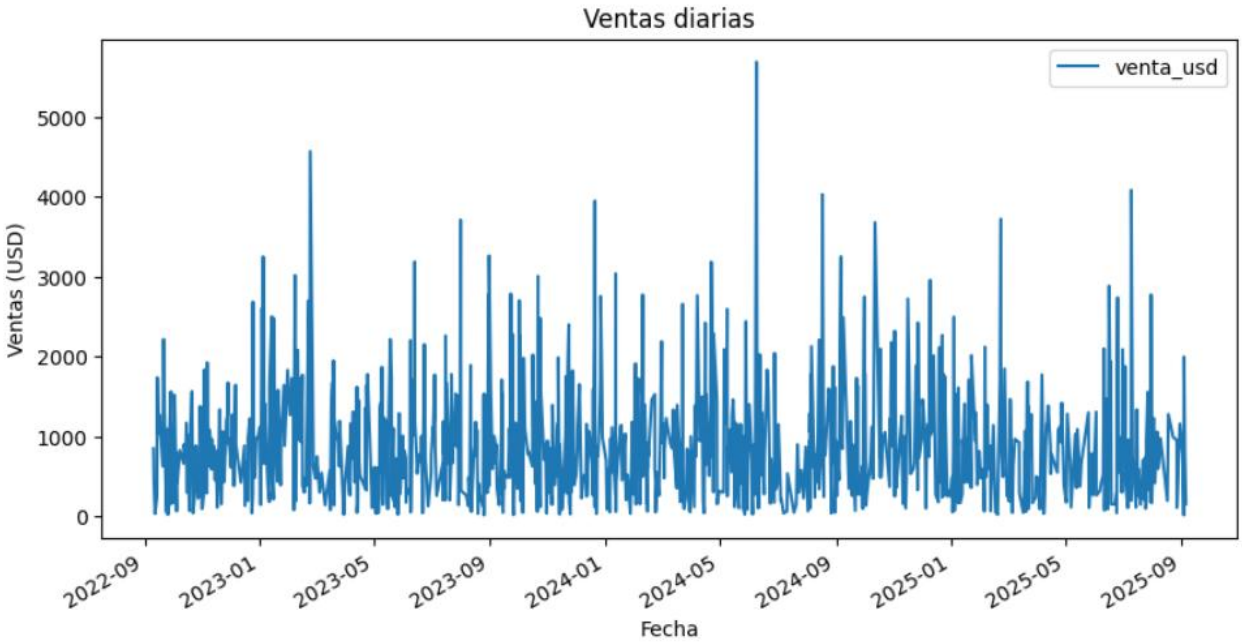

Interpretación: Se creó un indicador de ventas por día, calculado a partir de la cantidad de productos por pedido y su precio unitario. La evolución temporal mostró fluctuaciones diarias, con algunos picos de ventas que podrían corresponder a eventos promocionales o cierres de temporada.

4.3. Visualizaciones generales

En esta sección se presentan las estadísticas generales del análisis mediante diferentes representaciones gráficas, como histogramas, función de distribución empírica, diagramas de caja, matriz de correlación y línea de tiempo, entre otras.

4.3.1. Histogramas

Figura 19. Frecuencia de delta_days

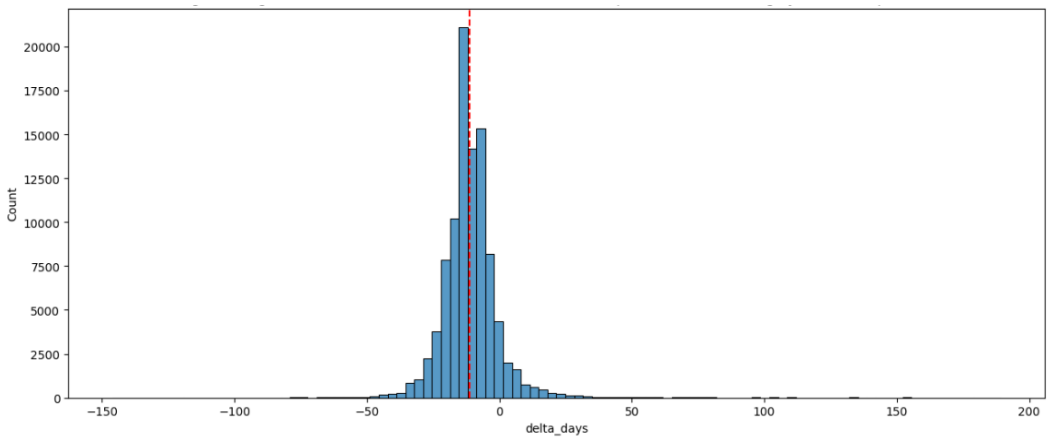

Interpretación: Como se aprecia, la diferencia de tiempo de estimado entrega y real tienen una distribución sesgada a la izquierda, hacia valores negativos, lo que concuerda con la idea de que casi todos los pedidos llegan antes de lo previsto.

Figura 20. Retrasos moderados vs prolongados

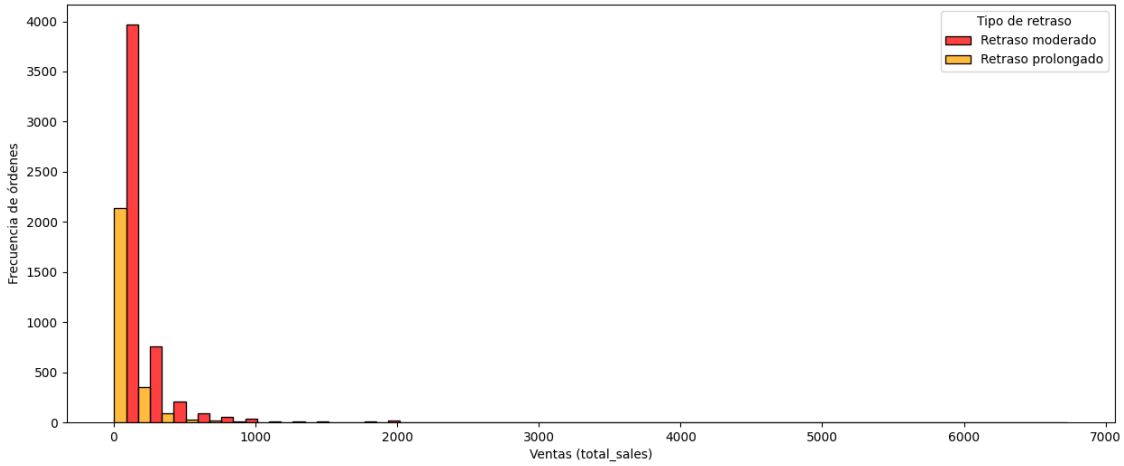

Interpretación: La mayoría de las órdenes con retraso, tanto moderado como prolongado, se concentran en ventas bajas (cerca de 0–500). A medida que aumentan las ventas, la frecuencia de pedidos con retrasos disminuye de forma marcada en ambos casos.

4.3.2. Función empírica

Figura 21. Tiempo estimado de entrega y real de los pedidos

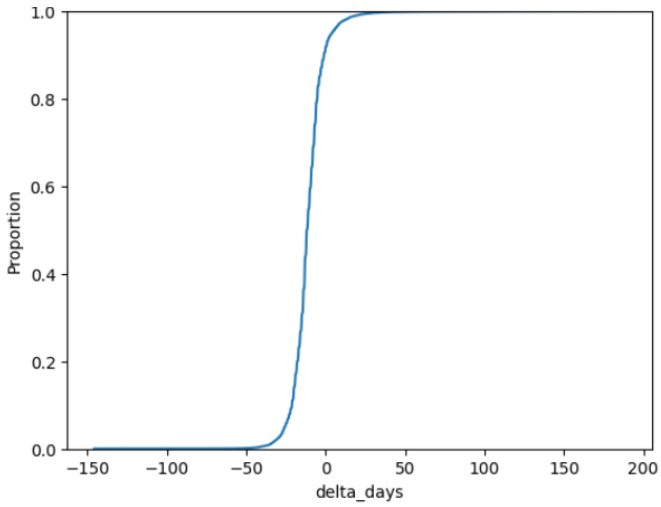

Interpretación: La proporción de casos en los que los pedidos llegan a tiempo corresponde a un poco más del 90%.

4.3.3. Serie de tiempo

Figura 22. Cantidad de envíos con retraso

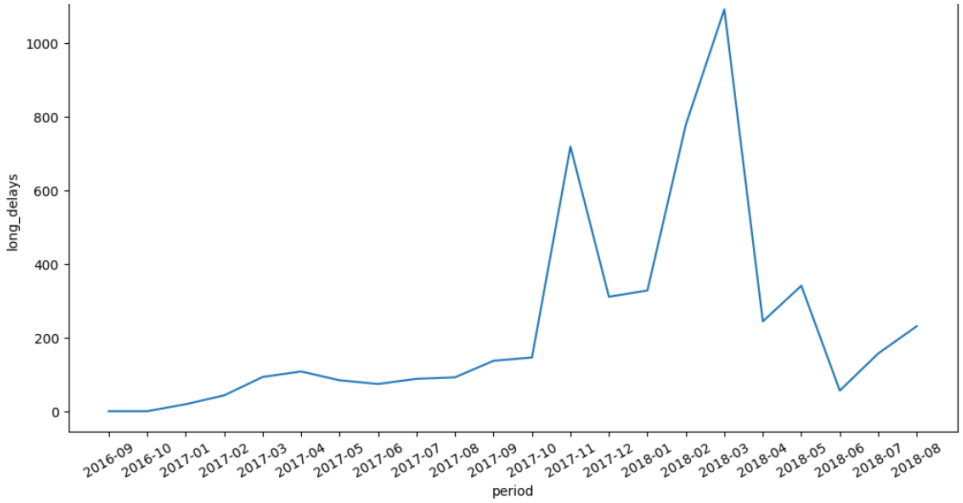

Interpretación: Se puede apreciar que desde octubre de 2017 la curva sube con fuerza, alcanza su pico en febrero-marzo de 2018 y en abril comienza a descender.

Figura 23. Cantidad de ordenes al mes con estados de entregas

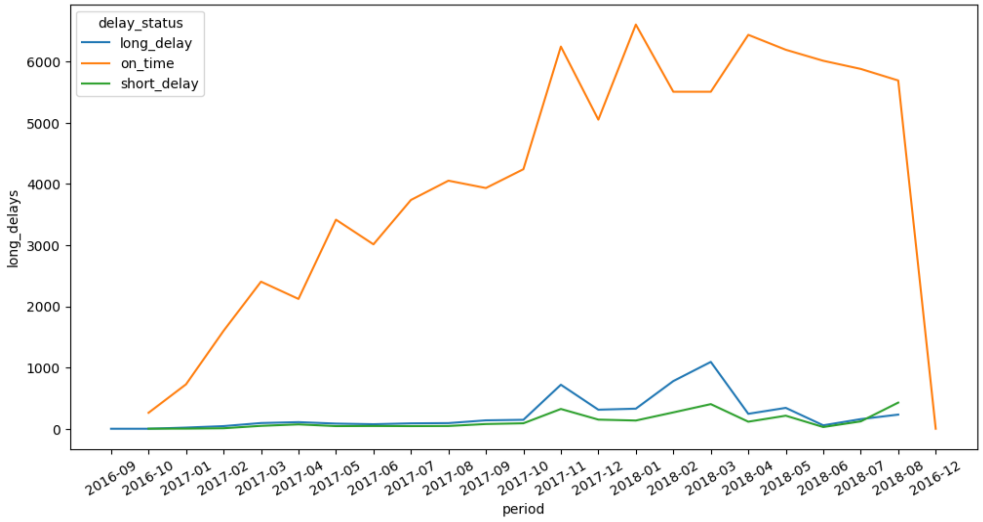

Interpretación: la mayoría de las órdenes se entregaron a tiempo, con una tendencia creciente hasta 2018, mientras que los retrasos largos y cortos fueron mucho menos frecuentes y con picos aislados, especialmente en los retrasos largos a inicios de 2018.

4.3.4. Diagrama de dispersión

Figura 24. Distancia y días de retrasos

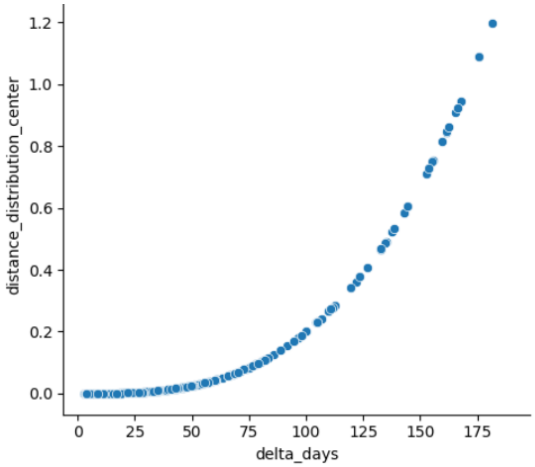

Interpretación: A mayor distancia al centro de distribución, más grande es el retraso en días.

4.3.5. Gráfica de barras

Figura 25. Conteo de ordenes y estado de llegada

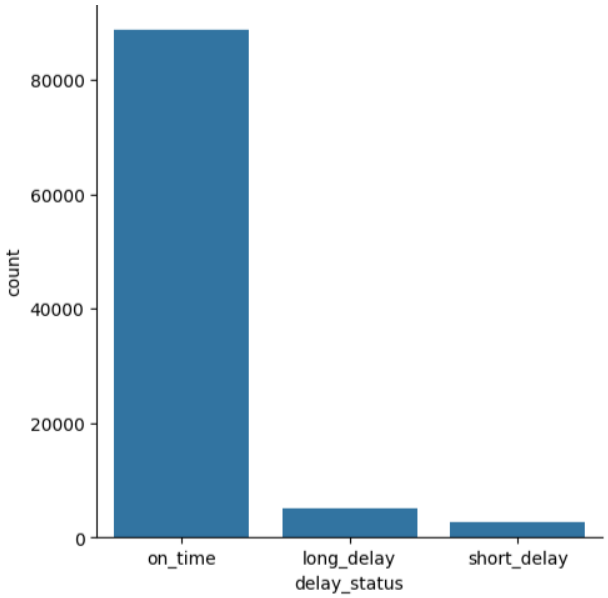

Interpretación: La mayoría de las órdenes llegan a tiempo, a su destino.

4.3.6. Matriz de correlación

Figura 26. Órdenes completadas

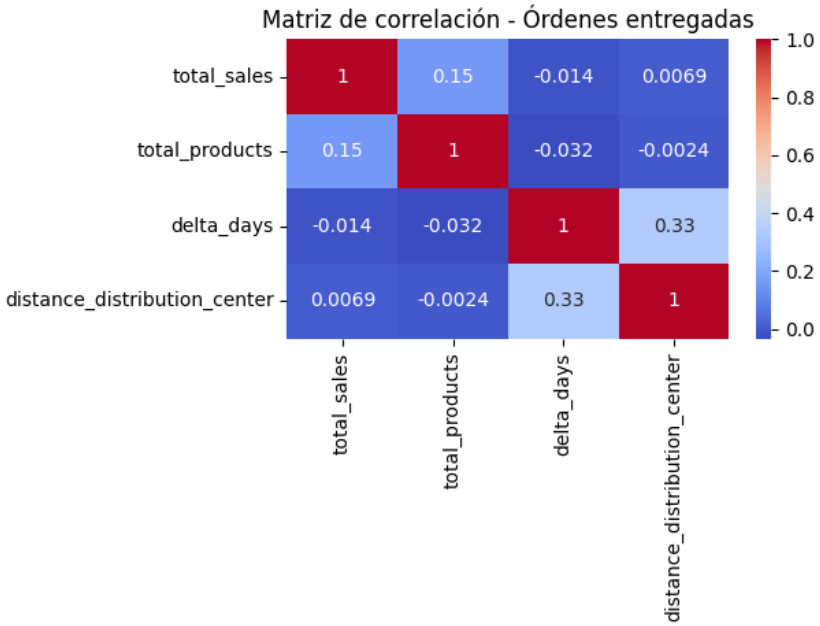

Interpretación: La correlación muestra que más productos se asocian levemente con mayores ventas y que los retrasos aumentan moderadamente con la distancia, sin relaciones relevantes con ventas o productos.

4.3.7. Diagrama de pares

Figura 27. Pair plots

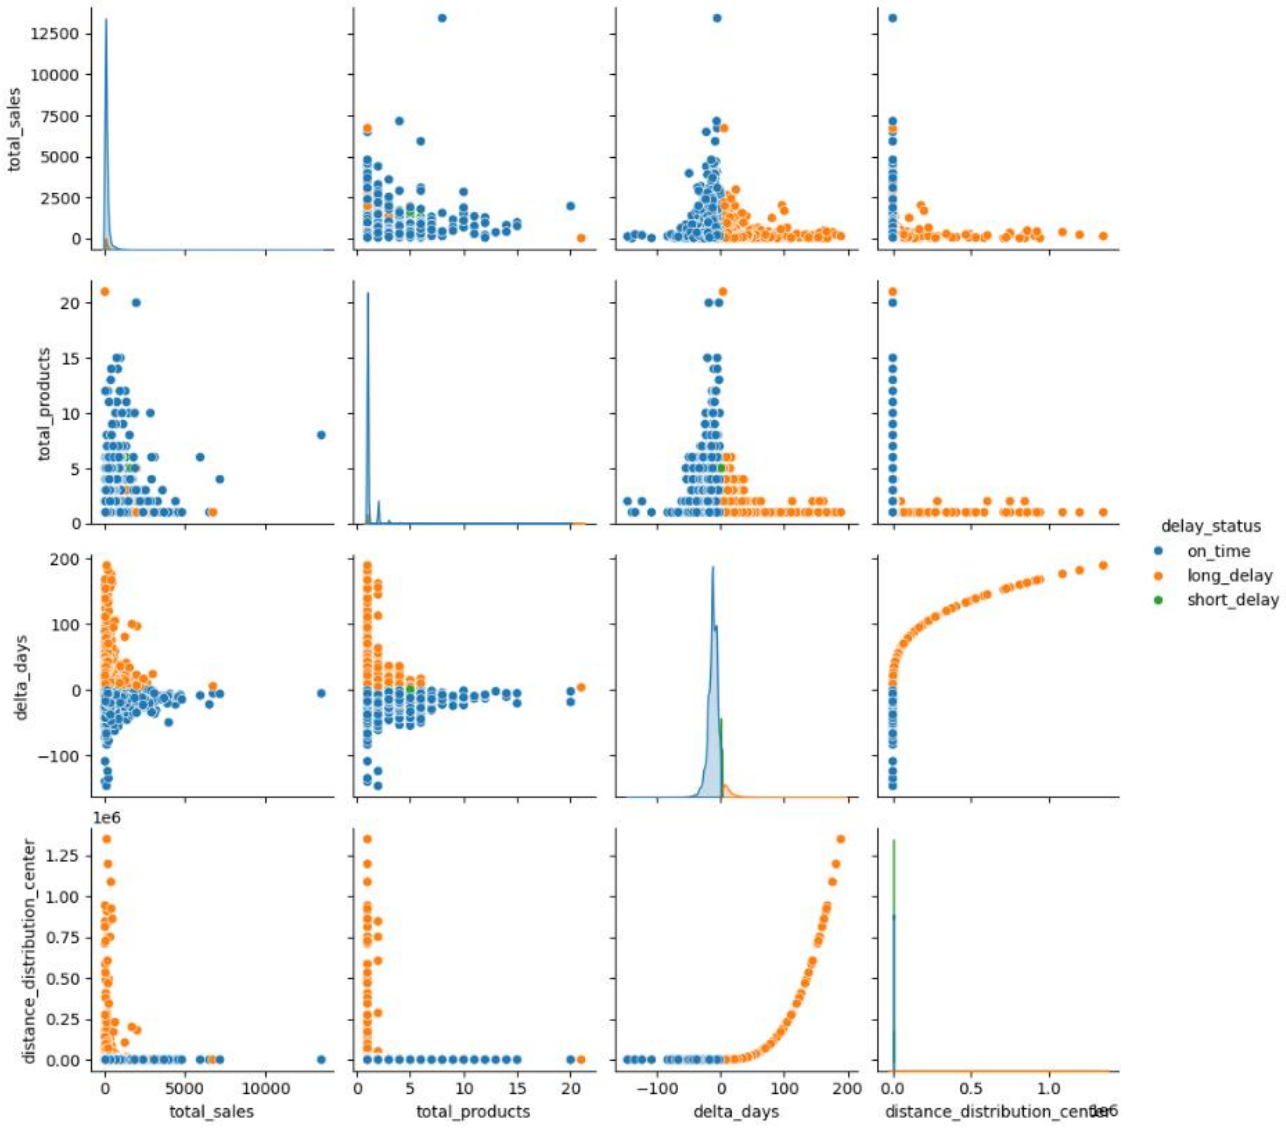

Interpretación: El gráfico de dispersión múltiple muestra que las ventas y el número de productos tienen una relación positiva aunque débil, mientras que los retrasos en días se asocian más con la distancia al centro de distribución. La mayoría de las órdenes, tanto a tiempo como con retraso, se concentran en valores bajos de ventas y productos, mientras que los retrasos largos aparecen con mayor frecuencia en distancias más grandes. En general, las variables de ventas no explican los retrasos, siendo la distancia el factor más relevante.

4.3.8. Diagrama de caja

Figura 28. Total de ventas y hora de llegada

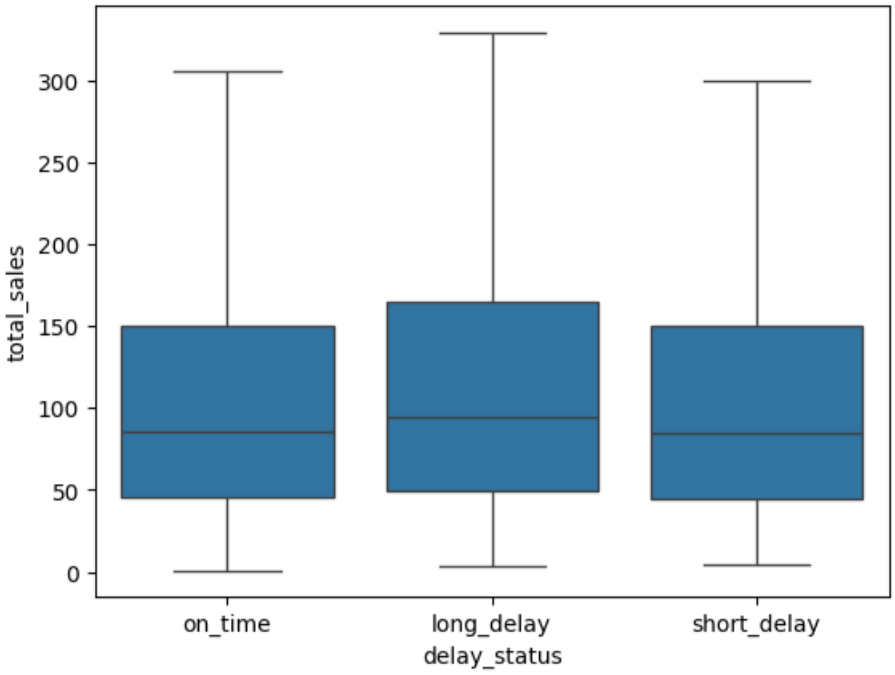

Interpretación: El monto de las órdenes no varía de forma sustancial entre entregas a tiempo o con retrasos, aunque las órdenes con retraso largo muestran una tendencia leve a ser de mayor valor.

Figura 29. Delta_days por estado y tipo de retraso

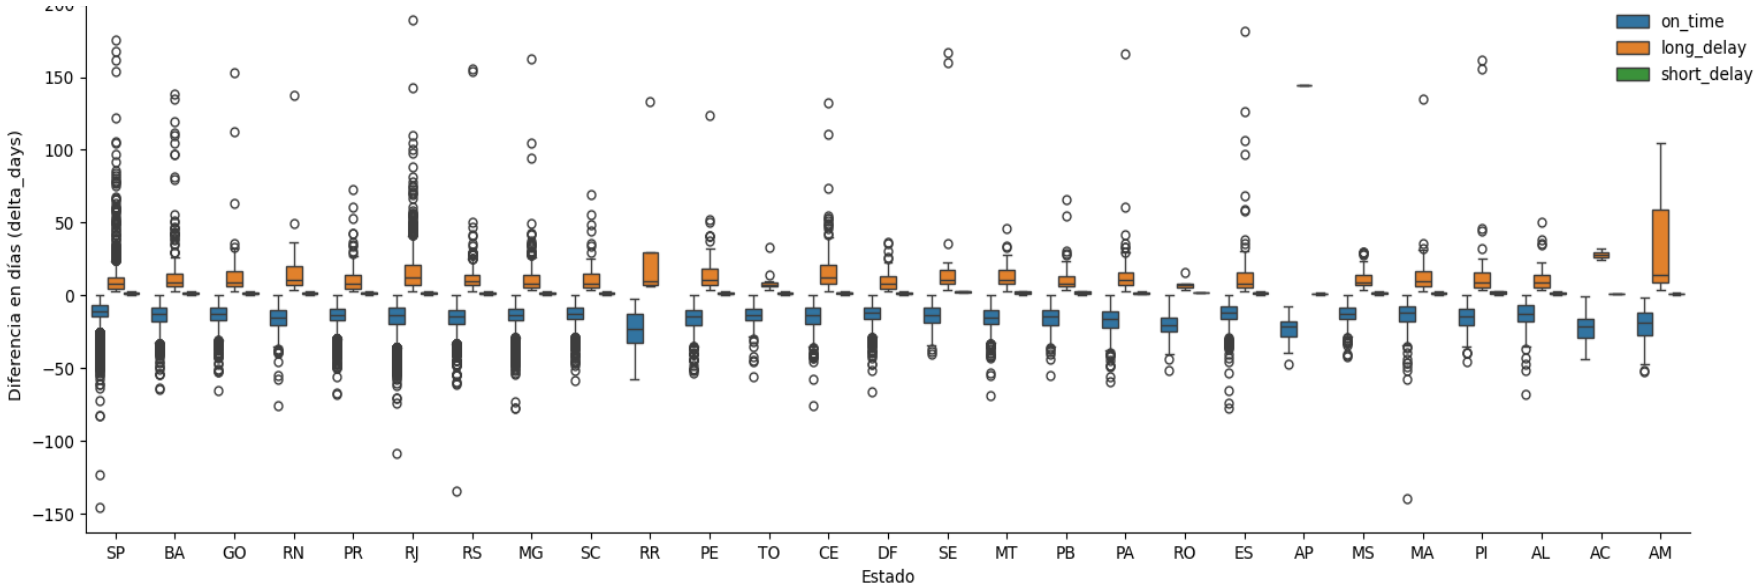

Interpretación: El gráfico muestra que en todos los estados de Brasil predominan las entregas a tiempo, aunque existen retrasos largos y cortos en menor proporción. Los retrasos largos presentan mayor dispersión y valores extremos en varios estados, destacando Amazonas (AM), donde los retrasos son más pronunciados. En general, los patrones de retraso se repiten en la mayoría de los estados, con variaciones en la magnitud y frecuencia de los outliers.

5. CONCLUSIONES Y RECOMENDACIONES

5.1. Conclusiones

- El análisis permitió integrar información dispersa de clientes, pedidos, productos, inventario, envíos, pagos y empleados en un solo modelo de datos coherente.
- La mayoría de los pedidos se completaron satisfactoriamente, aunque se detectaron cancelaciones y devoluciones que afectan el rendimiento del negocio.
- La distribución mensual de pedidos mostró picos de actividad en determinados meses, lo que evidencia patrones estacionales de demanda.
- Los pagos presentaron gran variabilidad, predominando montos pequeños y medianos, con algunos clientes de alto valor que representan transacciones importantes.
- El inventario global reflejó un control adecuado de stock, con cantidades que se ajustan a la demanda y muestran un sistema de reabastecimiento en funcionamiento.
- Las visualizaciones elaboradas facilitaron la interpretación de los resultados, aportando claridad sobre el comportamiento de ventas, clientes y procesos logísticos.
- El archivo consolidado generado constituye una base confiable para futuras aplicaciones de inteligencia de negocios y análisis predictivo.

5.2. Recomendaciones

- Automatizar los procesos de carga y limpieza de datos, para mantener la integridad y consistencia de la información en el tiempo.
- Monitorear cancelaciones y devoluciones con mayor detalle, identificando sus causas y proponiendo estrategias de retención de clientes.
- Optimizar la gestión logística mediante el análisis de los eventos de envío, para reducir tiempos de entrega y costos asociados.
- Aprovechar los patrones estacionales en la demanda para planificar campañas de marketing y ajustar inventario en meses de mayor actividad.
- Implementar paneles de control en BI (Power BI, Tableau u otros) que permitan seguimiento en tiempo real de ventas, clientes y logística.
- Ampliar el análisis en futuras etapas hacia modelos predictivos (predicción de demanda, segmentación de clientes, detección de riesgos de cancelación).

5.3. Apéndices

Debido a que el script de Python es muy extenso, adjunto el enlace al repositorio de GitHub, donde se encuentra el análisis completo del proyecto.

https://github.com/JuniorAcebo/Analisis-de-Datos